

谁更会算数学题？

GSM8K 上 Seq2Seq、Transformer 与大模型 对比实验

徐子锐

学号：19230444

班级：2304 班

2026 年 6 月 24 日

摘要

小学数学应用题要求模型同时读懂自然语言、找出数量关系并完成多步计算，比普通文本生成更看重数字正确性。我们在 GSM8K 数据集上比较了五条路线：从零训练的 RNN Seq2Seq 和 Transformer、预训练 T5、本地开源数学模型 Qwen2.5-Math-1.5B，以及 DeepSeek-V4-Flash/Pro API。所有模型共用 6725 条训练、748 条验证和 1319 条测试数据。除了 BLEU-4 和 ROUGE-L，我们设置三个更贴合数学任务的指标：最终答案准确率、格式合规率，以及用独立 GPT-5.5 评委对 100 条随机样本进行 0-2 分评级的 LLM 推理有效率。结果显示，从零训练的小模型能模仿部分输出格式，但最终答案准确率普遍低于 0.04；预训练 T5-base 提升到 0.052；本地 Qwen2.5-Math-1.5B 的 strict 准确率为 0.794，lenient/fallback 准确率为 0.799；DeepSeek-V4-Pro 和 Flash 分别达到 0.950 和 0.946。二者只相差 5 道题，McNemar 精确检验没有显示显著差异 ($p = 0.568$)。API 实验中，固定 prompt 前缀、warm-up 和并发请求让两个 DeepSeek 模型的上下文缓存命中率都超过 70%；按官方价格估算，本次 Flash 调用成本约为 0.125 美元，Pro 约为 0.428 美元。整体来看，模型规模与预训练显著提高数学推理能力，但评测结论也会受到答案解析规则、评委选择和成本约束的影响。

关键词：数学问答；GSM8K；Seq2Seq；Transformer；大语言模型；自动评价

1 引言

一道数学应用题，模型要过三关：读题、找关系、算对数。和普通文本生成不同，语言再流畅，最后数字错了就全错。GSM8K 数据集由 Cobbe 等提出，包含约 8.5K 道小学水平的应用题，是评估数学推理能力的常用测试场 [1]。

我们从 RNN Seq2Seq 出发，继续加入四条路线：自己从零实现的 Transformer、预训练好的 T5、本地可运行的 Qwen2.5-Math-1.5B，以及通过 API 调用的 DeepSeek-V4-Flash 和 DeepSeek-V4-Pro。核心问题很直接：同样面对 1319 道测试题，谁能算得最准？另一个问题同样重要：BLEU 和 ROUGE 这些文本生成指标，真的能反映数学能力吗？本报告现在最有价值的主线不是简单宣布“大模型第一”，而是把数学问答评测拆开看：最终答案是否正确、输出能否被稳定解析、推理过程是否可信，以及同样正确率需要付出多少成本。

2 任务与数据集

任务输入是一道英文小学数学应用题，输出需要包含必要的推理过程，并在末尾写出 GSM8K 标准答案行：#### number。这个格式看似简单，但对自动评测很关键；没有这一行，脚本就很难稳定抽取最终答案。

数据划分见表 1。所有模型都在同一份 test set 上汇报，避免因为测试集不同造成比较失真。

表 1: GSM8K 数据划分

划分	样本数
train	6725
dev	748
test	1319

3 实验方法

3.1 RNN Seq2Seq

RNN 是我们的基础基线。模型使用双层 BiGRU Encoder 和双层 GRU Decoder，中间加入 Bahdanau Attention 做对齐。最直接的版本叫 RNN full，它学习从题目到完整解题过程的映射。

完整解题过程对 RNN 来说太重了。它常能写出像 GSM8K 的公式模板，但答案并不可靠。因此我们又训练了 RNN final-only，让模型只输出 #### answer 这一行；解码时对比 greedy、beam=3 和 beam=5。

3.2 Transformer Seq2Seq

Transformer 采用 Vaswani 等提出的 encoder-decoder 自注意力结构 [2]，但不使用预训练权重。为了让比较尽量公平，tokenizer、词表和数据划分都与 RNN 路线保持一

致。

我们训练了 full-answer 和 final-only 两类版本。final-only 版本又做了两轮调参，包括增大模型维度、增加层数、加入 label smoothing、使用 cosine scheduler 和降低 dropout。这个设置检验的是：如果结构更强、训练更细，小模型能否靠自己学会数学推理。

3.3 预训练 T5

T5 将多种 NLP 任务统一为 text-to-text 形式 [3]。我们使用 FLAN-T5-small 和 FLAN-T5-base 做 final-only 微调，作为“从零训练 Transformer”的对照。FLAN-T5-small 的测试集最终答案准确率为 0.041698，低于 FLAN-T5-base 的 0.051554，因此主结果表只保留 T5-base。

T5-base 起初在 8GB 显存下直接 OOM。最后采用 Adafactor、gradient checkpointing、batch size 2、梯度累积 16 和较小 beam 设置完成训练。这个结果不算高，但它能回答一个问题：预训练确实有帮助，只是小规模 T5 仍远远不够。

3.4 本地开源大模型

本地路线选择 Qwen/Qwen2.5-Math-1.5B-Instruct。Qwen2.5-Math 是面向数学推理优化的模型系列 [4]，比通用模型更适合 GSM8K。实验采用 fp16、few-shot CoT prompt、max_new_tokens=512 和 batch size 4。完整 test 推理耗时约 72 分钟，CUDA reserved peak 约 3.279 GiB，没有出现显存溢出。

Qwen 原始输出中常用 `\boxed{}` 表示答案。评测脚本保留原始输出，同时把能明确解析的答案标准化为 `#### number`。为避免把解析规则和模型能力混在一起，我们同时报告 strict 和 lenient/fallback 两种准确率。strict 规则只接受明确最终答案行，共答对 1047 题，准确率为 0.793783；lenient 规则允许从 `\boxed{}` 或结尾数字中抽取明确答案，共答对 1054 题，准确率为 0.799090。也就是说，fallback 只额外找回 7 道正确题，Qwen 的 0.799 更接近一个保守但合理的估计，而不是靠宽松解析大幅抬高的结果。

3.5 DeepSeek API 大模型

DeepSeek 路线测试了 DeepSeek-V4-Flash 和 DeepSeek-V4-Pro。根据 DeepSeek 官方文档，V4-Flash 与 V4-Pro 都支持 1M 上下文，输入 token 会区分 cache hit 和 cache miss 计费 [5]；上下文缓存默认开启，后续请求只要完整复用已持久化的公共前缀，就会计入 prompt_cache_hit_tokens [6]。因此，prompt 被拆成固定前缀和变量题目两部分，few-shot 示例放在题目前面。高并发前先顺序 warm-up 3 个请求，等缓存落盘后再用 20 workers 并发推理。脚本记录 prompt_cache_hit_tokens 和 prompt_cache_miss_tokens，用于统计缓存命中和估算 API 成本。

DeepSeek 输出还会经过最终答案行修复和数值归一化，避免 7.00 与 7 这种等价答案被误判。

4 评价指标

BLEU 和 ROUGE 不够用。它们看的是生成文本和参考答案的词语重合度；如果模型学会了参考答案的写法，分数可能不错，但数字仍然可能错。反过来，一个模型用不同表述把题讲对了，也可能被 BLEU 扣分。因此，BLEU-4 和 ROUGE-L 只作为辅助参考，不用于判断谁更会解题。

真正和数学问答直接相关的是下面三个指标：

1. **最终答案准确率**：从 ##### 后抽取最终数字，与标准答案比对，并处理 7.00 与 7 这类等价情况。这是硬指标，对了就是对了。
2. **格式合规率**：输出里是否有可解析的 ##### 答案行。没有这一行，后面的自动评测就不稳定。
3. **LLM 推理有效率**：随机抽取 100 个测试样本，让独立 GPT-5.5 评委对推理过程打 0、1、2 分。2 分表示推理基本正确且答案正确，1 分表示推理部分有效但有跳步或不完整，0 分表示无有效推理或严重错误；最后把平均分除以 2，归一化到 0-1。早期版本用 DeepSeek-V4-Pro 做评委，但它同时也是被测模型之一，因此本文主表改用独立评委结果。

另外，full-answer 模型有时会生成 GSM8K 标准公式标记 << 表达式 = 结果 >>。我们额外计算公式执行准确率，但不把它作为主指标。它的作用很窄：判断模型是在真计算，还是只学会了公式模板的外观。

5 实验结果

5.1 主结果对比

表 2 汇总了各模型在同一测试集上的表现。先看最终答案准确率，差距很大。

DeepSeek-V4-Pro 在本次单次测试中最高，达到 0.950；Flash 很接近，为 0.946。换句话说，这两个云端模型大约每 20 道题错 1 道。本地可运行的 Qwen2.5-Math-1.5B lenient 准确率为 0.799，约等于每 5 道题答对 4 道，而且不依赖网络。

真正拉开差距的是从零训练的小模型。调参后的 Transformer final opt 是自实现模型里最好的，最终答案准确率也只有 0.035；RNN full 为 0.025。它们不是偶尔犯错，而是还没有真正学会多步算术。

表 2: 同一测试集上的代表性模型自动评价结果

模型	类别	BLEU-4	ROUGE-L	最终答案准确率	格式合规率
RNN full	RNN	0.129968	0.389191	0.025019	0.903715
Transformer full	Transformer	0.053301	0.193792	0.004549	0.245641
Transformer final opt	Transformer optimized	0.000000	0.037787	0.034875	1.000000
Pretrained T5-base final	Pretrained Transformer	0.000000	0.027939	0.051554	1.000000
Local Qwen2.5-Math-1.5B CoT	Local open LLM	0.122963	0.291846	0.799090	0.953753
DeepSeek-V4-Flash API	Hosted LLM	0.173545	0.390629	0.946171	1.000000
DeepSeek-V4-Pro API	Hosted LLM	0.188433	0.416396	0.949962	1.000000




图 1: 最终答案准确率与 GPT-5.5 推理有效率




图 2: BLEU-4 与 ROUGE-L 辅助文本相似度指标

BLEU 和 ROUGE 的结果也印证了前面的担心：文本重合不等于会算题。Qwen2.5-Math-1.5B 的 BLEU-4 为 0.122963，略低于 RNN full 的 0.129968，但最终答案准确率是 0.799090，远高于 RNN full 的 0.025019。T5-base final 的 BLEU-4 为 0，最终答案准确率却达到 0.051554，高于 Transformer full 的 0.004549。也就是说，一个模型可能很会模仿参考答案的语言模板，却几乎不会算。

5.2 任务相关指标结果

表 3 列出三个任务相关指标。它们比 BLEU 更直接：最终答案准确率看是否算对，格式合规率看能否被自动批改，LLM 推理有效率则检查推理过程有没有明显漏洞。

表 3: 任务相关指标对比

模型	最终答案准确率	格式合规率	GPT-5.5 推理有效率
RNN full	0.025019	0.903715	0.015
Transformer full	0.004549	0.245641	0.000
Local Qwen2.5-Math-1.5B	0.799090	0.953753	0.860
DeepSeek-V4-Flash	0.946171	1.000000	0.960
DeepSeek-V4-Pro	0.949962	1.000000	0.965




图 3: Qwen2.5-Math-1.5B 的 strict 与 lenient/fallback 解析结果

图 3 单独展示 Qwen 的解析问题。strict 准确率为 0.794，lenient/fallback 准确率为 0.799，二者差距只有 0.005。这个结果说明，Qwen 的主要差距不是解析规则造成的；即使用更宽松的抽取方式，也只额外找回 7 道正确题。

5.3 补充诊断

图 4 解释了 RNN full 的一个典型问题：它很会写“像答案的答案”。RNN full 的公式覆盖率达到 0.939348，但公式执行准确率只有 0.074517；Transformer full 的公式覆盖率和公式执行准确率分别为 0.415466 和 0.034143。格式像，并不代表计算对。




图 4: full-answer 模型的公式执行诊断

5.4 大模型双路径与成本

Qwen2.5-Math-1.5B 的价值在于可本地复现，不产生 API 调用费用。DeepSeek-V4-Flash 和 DeepSeek-V4-Pro 更强，最终答案准确率和格式稳定性都更高。图 5 显示，DeepSeek-V4-Flash 的 prompt cache hit rate 为 0.743287，DeepSeek-V4-Pro 为 0.707959。固定前缀和 warm-up 确实复用了大部分公共 prompt；由于 DeepSeek 文档说明缓存命中是 best-effort 机制，本文不对 Flash 和 Pro 的命中率差异做过强解释。




图 5: DeepSeek 上下文缓存命中情况

按 DeepSeek 官方 2026 年 6 月价格估算, Flash 本次 1319 条测试调用约花费 0.125 美元, Pro 约花费 0.428 美元。两者准确率只差 0.0038, 但 Pro 成本约为 Flash 的 3.4 倍。配对 McNemar 精确检验中, Pro 独有正确 27 题, Flash 独有正确 22 题, $p = 0.568$ 。因此, 本文只说 Pro 在本次测试中略高, 不把它写成统计意义上的显著优势。

表 4: DeepSeek 双模型的成本与显著性对比

模型	准确率	估算成本 (USD)	每答对一题成本	缓存命中率
DeepSeek-V4-Flash	0.946171	0.124653	0.000100	0.743287
DeepSeek-V4-Pro	0.949962	0.427717	0.000341	0.707959




图 6: DeepSeek 双模型的成本-准确率权衡

5.5 LLM 抽样复核

表 5 是 100 条随机样本的 GPT-5.5 独立复核结果。DeepSeek-V4-Flash 和 DeepSeek-V4-Pro 的推理有效率分别为 0.960 和 0.965, 本地 Qwen 为 0.860。RNN full 和 Transformer full 基本没有通过复核; 它们生成的文本有时像推理, 但评委很少认为它们真的讲通了。

表 5: 随机 100 条样本的 GPT-5.5 独立评委复核结果

模型	样本数	平均分	推理有效率	2 分比例	0 分比例
RNN full	100	0.03	0.015	0.00	0.97
Transformer full	100	0.00	0.000	0.00	1.00
Local Qwen2.5-Math-1.5B	100	1.72	0.860	0.77	0.05
DeepSeek-V4-Flash	100	1.92	0.960	0.94	0.02
DeepSeek-V4-Pro	100	1.93	0.965	0.95	0.02

LLM 复核很方便，但不能当成人工标注的完全替代。为避免 DeepSeek-V4-Pro 既当选手又当唯一裁判，本文主表使用 GPT-5.5 作为独立评委；原 DeepSeek-Pro 评委结果只作为早期对照。即便如此，100 条样本也只能观察主要趋势，覆盖不了全部细粒度错误。所以这个指标只用于辅助分析，不单独决定最终排名。

6 错误分析与讨论

小模型的两种失败方式。 RNN full 和 Transformer full 都失败，但失败方式不同。RNN full 其实学会了 GSM8K 的表面形式：它经常生成公式标记，格式也不算差。问题在于它算不对。Transformer full 更靠前一步就掉下去了，格式合规率只有 0.245641，很多输出里根本找不到 #####。

表 6 给出 3 个真实错误样例。第一个样例中，RNN full 生成了 $\langle\langle \dots = \dots \rangle\rangle$ 形式的公式标记，但表达式和结果并不匹配，最后输出 ##### 120，标准答案是 18。第二个样例中，Transformer full 反复生成无意义短语，没有生成最终答案行。第三个样例中，Qwen 已经推到正确答案附近，但输出在 \boxed 附近截断，导致 strict 格式解析失败。

表 6: 典型错误样例

题目简述	标准答案	模型输出片段	错误类型
鸭蛋每日收入题	##### 18	RNN full 输出 $\langle\langle 12*12=12 \rangle\rangle$ 、 $\langle\langle 12*12=120 \rangle\rangle$ ，最后给出 ##### 120。	公式格式像，但计算错
房屋翻修利润题	##### 70000	Transformer full 反复生成 “the price of the price”，没有输出 ##### 最终答案行。	格式不可解析
自行车打气收费题	##### 5	Qwen 推理到 500 cents = 5 dollars，但结尾停在 \boxed，strict 解析不到最终答案。但格式截断	推理接近正确，但格式截断

除了个别样例，我们还统计了 Qwen 与两个 DeepSeek 模型的错误类型，结果见图 7。Qwen 的错误主要是最终数字错误（204 条）和缺少明确最终答案标记（54 条），另有 7 条属于 “strict 抽不到但 fallback 抽对”。DeepSeek-Flash 和 DeepSeek-Pro 的格式合规率均为 1.0，剩余错误主要是答案本身错误，分别为 71 条和 66 条。这说明大模型后 5% 左右的错误已经不是模板失败，而是题意理解、边界条件或多步计算中的真实错误。




图 7: Qwen 与 DeepSeek 的错误类型统计

只改输出目标，不会自动带来推理能力。final-only 模型把目标压缩到最终答案，格式合规率立刻变成 1.0，但准确率几乎没有本质提升。Transformer final optimized 是自实现模型中的最佳结果，最终答案准确率为 0.034875。它比 full-answer Transformer 好一些，但离“会解题”还很远。

预训练有用，但不够。 T5-base 相比自实现 Transformer 有提升，准确率达到 0.051554。这个提升说明预训练确实提供了更好的语言建模基础；但只做 final-only 微调、模型规模又有限，它仍不能稳定解决 GSM8K 的多步推理。

大模型为什么强？ Qwen2.5-Math-1.5B 是数学专项模型，训练中接触过大量解题链，因此即使只有 1.5B 参数，也能在本地跑到 0.799090。DeepSeek 系列更强，Flash 和 Pro 分别达到 0.946171 和 0.949962，格式合规率均为 1.0。但二者只差约 5 道题，统计检验不支持“Pro 显著强于 Flash”的说法。结合成本，Flash 更适合成本敏感场景；Pro 是否值得额外成本，需要看任务是否真的需要那一点点单次精度优势。

7 结论

同一批 GSM8K 测试题，把模型差距拉得很开。我们得到三个结论。

- **模型规模和预训练显著提高上限。** 从零训练的小模型最终答案准确率低于 0.04；1.5B 的数学专项模型 Qwen2.5-Math-1.5B 达到 0.799；DeepSeek-V4-Pro 和 Flash 则接近 0.95。
- **BLEU/ROUGE 会误导数学问答评测。** RNN full 的 BLEU-4 略高于 Qwen，但最终答案准确率相差 30 倍以上。数学问答必须看最终数字和推理过程。
- **本地部署和云端 API 各有位置。** Qwen2.5-Math-1.5B 可以离线复现，适合成本

和隐私敏感场景；DeepSeek-Flash 以明显更低成本接近 Pro；Pro 在本次测试中略高，但优势没有通过配对显著性检验。

实验仍有局限。Qwen LoRA 微调脚本已经补充到工程中，但由于本机环境首次加载模型耗时较长，最终论文主表仍采用已完整跑完的 few-shot 结果；DeepSeek 的缓存命中率超过 70%，但没有系统比较不同 prompt 结构的影响；GPT-5.5 评委比 DeepSeek 自评更独立，但仍不能完全替代人工标注。还有一个值得继续追问的问题：DeepSeek-Pro 仍有约 5% 的题目算错，这些错误到底来自计算、推理，还是题目表述本身？后续可以加入 SVAMP、MultiArith 等数据集，并对 prompt 数量、温度、LoRA 微调轮数和人工评委一致性做更细的消融。

A 大模型提示词模板

Qwen 与 DeepSeek 都使用少量示例引导模型按步骤计算，并要求最终答案使用统一格式。DeepSeek API 实验把示例部分作为固定前缀，以提高上下文缓存命中率。简化模板如下：

```
You are a precise GSM8K math solver.  
Solve arithmetic word problems carefully.  
Show concise step-by-step arithmetic.  
The final line must be exactly: ##### number
```

Example 1:

```
Question: A store has 12 pencils. It buys 8 more pencils  
and then sells 5. How many pencils are left?
```

```
Answer:
```

```
The store has  $12 + 8 = 20$  pencils after buying more.
```

```
After selling 5, it has  $20 - 5 = 15$  pencils left.
```

```
##### 15
```

```
Now solve:
```

```
Question: {question}
```

```
Answer:
```

参考文献

- [1] Cobbe K, Kosaraju V, Bavarian M, et al. Training Verifiers to Solve Math Word Problems. arXiv:2110.14168, 2021. <https://arxiv.org/abs/2110.14168>
- [2] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017. <https://arxiv.org/abs/1706.03762>
- [3] Raffel C, Shazeer N, Roberts A, et al. Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. Journal of Machine Learning Research, 2020. <https://arxiv.org/abs/1910.10683>
- [4] Yang A, Li B, Hui B, et al. Qwen2.5-Math Technical Report: Toward Mathematical Expert Model via Self-Improvement. arXiv:2409.12122, 2024. <https://arxiv.org/abs/2409.12122>
- [5] DeepSeek. Models & Pricing. https://api-docs.deepseek.com/quick_start/pricing
- [6] DeepSeek. Context Caching. https://api-docs.deepseek.com/guides/kv_cache